

Rastreamento de Experimentos de ML com Weights & Biases

IMD3005 - MLOPS

Prof. Adelson de Araújo

Este laboratório dá continuidade ao **Laboratório 1 (ETL + Feature Engineering com Apache Airflow)**. As features produzidas naquele pipeline, ou um dataset alternativo à sua escolha, agora alimentam um modelo scikit-learn simples, cujos hiperparâmetros serão otimizados com sweeps do W&B.

O objetivo é praticar o ecossistema do W&B: sweeps, logging de métricas, comparação de runs, artifacts (versionamento de dataset e modelo) e reports.

Ao final da atividade, o aluno deve ser capaz de:

- Instrumentar um script de treino com Weights & Biases (`wandb.init`, `wandb.log`) do zero.
- Explicar por que busca sistemática de hiperparâmetros (sweeps) é preferível a ajuste manual por tentativa e erro em um pipeline de MLOps.
- Configurar e rodar um W&B Sweep via arquivo YAML, justificando a escolha da estratégia de busca (`grid`, `random` ou `bayes`) para o problema.
- Logar métricas de treino, teste, cross-validation e importância de features (via `permutation_importance`) a cada run.
- Versionar dataset e modelo como W&B Artifacts.
- Ler e interpretar o **parallel coordinates plot** e o painel de **hyperparameter importance** do W&B para entender o que mais influenciou a métrica.
- Consolidar tudo em um **W&B Report**, com esses gráficos incorporados ao vivo e os artifacts linkados, justificando a decisão com base nos runs executados.

Pré-requisitos e mini-onboarding em W&B

Pré-requisitos técnicos: Python 3.9+, `scikit-learn`, `pandas`, ambiente virtual ou notebook (Colab/Jupyter), e o `features.csv` produzido no Laboratório 1 — ou outro dataset tabular de sua escolha, caso prefira treinar um modelo diferente. Como a turma nunca usou W&B, a atividade inclui uma etapa 0 obrigatória antes do desafio principal.

Etapa 0 — Hello World do W&B (antes do desafio, ~30-45 min):

1. Criar conta gratuita em wandb.ai.
2. Instalar a biblioteca: `pip install wandb`.
3. Autenticar no terminal: `wandb login` (copiar a API key do site).
4. Rodar um script trivial que treina um modelo fixo (ex.: `RandomForestClassifier` com hiperparâmetros padrão no dataset Iris) e loga a acurácia com `wandb.init(project="mlops-wandb-intro")` e `wandb.log({"accuracy": acc})`.
5. Confirmar no dashboard do W&B que o run apareceu, com a métrica logada.

Esse checkpoint garante que todo mundo chega ao desafio de sweeps com o ambiente funcionando — problemas de conta, autenticação ou instalação são resolvidos aqui, não durante o desafio em si.

Dataset, features e modelo

Este laboratório conecta-se diretamente ao Laboratório 1. Duas opções de dataset são válidas:

- **Opção A — reaproveitar o Laboratório 1:** use o `features.csv` gerado pelo seu pipeline de Airflow como entrada para um modelo scikit-learn simples (classificação ou regressão, conforme o problema dos seus dados).
- **Opção B — outro dataset:** escolha livremente outro dataset tabular e um modelo scikit-learn simples, sem restrição de origem ou API.

Em ambos os casos, o foco da atividade não é a complexidade do modelo, e sim praticar os recursos do W&B (sweeps, logging, artifacts e reports) sobre features que você mesmo produziu ou escolheu.

Para conseguirmos focar no objetivo central da tarefa (praticar o uso do W&B), prefira um modelo simples (ex.: `RandomForestClassifier`, `GradientBoostingClassifier`, `LogisticRegression`, `SVC`) com 4-6 hiperparâmetros relevantes, um espaço de busca com poucas dimensões torna o `parallel coordinates plot` e o `hyperparameter importance` do W&B mais fáceis de ler e interpretar.

Métrica de otimização sugerida: acurácia ou F1 macro (classificação) ou RMSE/R² (regressão). A cada run do sweep, você deve logar no W&B: a métrica de performance nos dados de treino, a métrica nos dados de teste (hold-out), o score de validação cruzada (`cross_val_score`, 5 folds), a importância das features calculada com `permutation_importance` (método aplicável a qualquer estimador, ao contrário do `feature_importances_` nativo de modelos baseados em árvore) e a configuração de hiperparâmetros usada.

O desafio

O núcleo da atividade é usar o W&B Sweep de forma criteriosa e justificar a estratégia de busca escolhida para o problema, extraindo dele evidências que sustentem sua análise (métricas, importância de features, custo computacional).

1. Definir o espaço de busca (quais hiperparâmetros, quais faixas/valores) para o modelo escolhido — poucas dimensões (4-6) deixam os gráficos do W&B mais legíveis.
2. Escolher UMA estratégia de sweep do W&B (`grid`, `random` ou `bayes`) e justificar a escolha para o problema.
3. Em cada run, logar no W&B: métrica de treino, métrica de teste, cross-validation, importância das features (via `permutation_importance`) e a configuração de hiperparâmetros.
4. Explorar o **parallel coordinates plot** do sweep no W&B: quais faixas de hiperparâmetros levam aos melhores runs? Há algum padrão visual claro?
5. Explorar o **feature importance** do W&B: quais features mais influenciam o modelo? O resultado bate com sua intuição?
6. Ao final do sweep, salvar como W&B Artifacts o dataset utilizado e o melhor modelo (segundo a métrica escolhida).
7. Montar um **W&B Report** com os dois gráficos acima incorporados como painéis ao vivo (não como imagem) e os links dos artifacts.
8. Investigar pelo menos uma pergunta exploratória à escolha (ou propor outra):
 - Há sinais de overfitting ao comparar métrica de treino vs. teste ao superotimizar hiperparâmetros?
 - As features mais importantes (via `permutation importance`) fazem sentido no domínio do problema?

Configuração do sweep e código inicial

Exemplo adaptando o pipeline do Laboratório 1, ajuste os nomes de colunas, o modelo e os hiperparâmetros caso esteja usando a Opção B.

train.py:

```
import wandb
import joblib
import pandas as pd
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import train_test_split, cross_val_score
from sklearn.inspection import permutation_importance

def main():
    run = wandb.init(project="mlops-lab2-sweep")
    config = wandb.config

    # features.csv do Laboratorio 1 ou outro dataset tabular
    df = pd.read_csv("features.csv")
    X = df.drop(columns=["target"]) # ajuste para o nome real da coluna-alvo
    y = df["target"]

    X_train, X_test, y_train, y_test = train_test_split(
        X, y, test_size=0.2, random_state=42
    )

    model = RandomForestClassifier(
        n_estimators=config.n_estimators,
        max_depth=config.max_depth,
        min_samples_split=config.min_samples_split,
        min_samples_leaf=config.min_samples_leaf,
        max_features=config.max_features,
        random_state=42,
    )
    model.fit(X_train, y_train)

    train_score = model.score(X_train, y_train)
    test_score = model.score(X_test, y_test)
    cv_scores = cross_val_score(model, X_train, y_train, cv=5, scoring="f1_macro")

    wandb.log({
        "train_score": train_score,
        "test_score": test_score,
        "cv_f1_macro_mean": cv_scores.mean(),
        "cv_f1_macro_std": cv_scores.std(),
    })

    # Importancia das features via permutation importance
    # (funciona para qualquer estimador)
    perm = permutation_importance(model, X_test, y_test, n_repeats=10, random_state=42)
    importance_table = wandb.Table(
        data=list(zip(X.columns, perm.importances_mean, perm.importances_std)),
        columns=["feature", "importance_mean", "importance_std"],
    )
    wandb.log({"feature_importance": importance_table})

    # Artifact do dataset (o W&B deduplica pelo hash do arquivo)
    dataset_artifact = wandb.Artifact("features-dataset", type="dataset")
    dataset_artifact.add_file("features.csv")
    run.log_artifact(dataset_artifact)

    # Artifact do modelo deste run
    joblib.dump(model, "model.joblib")
    model_artifact = wandb.Artifact(
        f"model-{run.id}", type="model", metadata=dict(config)
    )
    model_artifact.add_file("model.joblib")
    run.log_artifact(model_artifact)

if __name__ == "__main__":
    main()
```

sweep.yaml:

```
method: bayes # escolha grid, random ou bayes
              # e justifique a escolha no seu Report
metric:
  name: cv_f1_macro_mean
  goal: maximize
parameters:
  n_estimators:
    values: [50, 100, 200, 400]
  max_depth:
    values: [3, 5, 10, 20, null]
  min_samples_split:
    values: [2, 5, 10]
  min_samples_leaf:
    values: [1, 2, 4]
  max_features:
    values: ["sqrt", "log2", null]
program: train.py
```

Comandos:

```
wandb sweep sweep.yaml # retorna um SWEEP_ID
wandb agent <SWEEP_ID> # executa os runs, pode configurar o numero de tentativas
```

Limite o número de runs a um valor razoável para o espaço de busca escolhido (ex.: `wandb agent <SWEEP_ID> --count 40`).

Ao final, acesse a aba **Artifacts** do projeto no W&B, identifique o run com melhor `cv_f1_macro_mean` e marque seu artifact de modelo com o alias `best` (clique no artifact → “+ Add alias”) para deixá-lo fácil de localizar no seu Report.

Entregáveis e avaliação

Entregáveis:

Link do **W&B Report**, contendo:

- espaço de busca de hiperparâmetros escolhido, estratégia de sweep utilizada e justificativa da escolha;
- o **parallel coordinates plot** do sweep.
 - **Importante!** Nesse plot, selecione somente as colunas sendo somente os hiperparâmetros e a última coluna sendo a métrica de performance do modelo, incorporado como painel ao vivo (não como imagem);
- melhor resultado/modelo obtido (métrica, número de runs, tempo);
- o gráfico de **feature importance** **somente do melhor modelo**, também como painel ao vivo no Report;
- os links dos **artifacts** do dataset e do melhor modelo;

Cronograma sugerido (1 semana)

Dia	Atividade
#1	Etapa 0: conta no W&B, instalação, hello world de logging
2–3	Escolha do dataset/modelo, definição do espaço de busca e da estratégia de sweep, primeiro sweep pequeno (poucos runs) para validar o pipeline
4–5	Sweep completo com a estratégia escolhida, investigação da pergunta exploratória
6	Análise dos resultados no dashboard (parallel coordinates plot, hyperparameter importance)
7	Relatório final (W&B Report) e entrega

Recursos e links de apoio

- wandb.ai — criar conta gratuita
- [Integração W&B com scikit-learn](#)
- [W&B Sweeps — documentação oficial](#)
- [W&B Sweeps quickstart](#)
- [Configuração do sweep \(YAML\) — referência de parâmetros](#)
- [W&B Artifacts — documentação oficial](#)
- [W&B Reports — documentação oficial](#)